

נושאים מתקדמים בראייה חاسوبית - הרצאה #12

נושאי השיעור:

- Back prop
- Alex net

תצבורת רשת היא אסף של משקולות - $w_{ij}^{(l)}$ (פירוט בשיעור קודם)
 עצבון למשקולות נוסף במטרה להקטין את השגיאה שמקבלת לאחר העדכון.

$$\Delta w = \frac{\partial e(w)}{\partial w_{ij}^{(l)}} = ?$$

$$e(w) = (x_1^{(L)} - y)^2$$

$$\frac{\partial e(w)}{\partial w_{ij}^{(l)}} = \underbrace{\frac{\partial e(w)}{\partial s_j^{(l)}}}_{\delta_j^{(l)}} \cdot \underbrace{\frac{\partial s_j^{(l)}}{\partial w_{ij}^{(l)}}}_{x_i^{(l-1)}}$$

$$\left(s_j^{(l)} = \sum_{i=0}^{d^{(l-1)}} w_{ij}^{(l)} x_i^{(l-1)} \right) \quad (\text{תצבורת})$$

$$\Rightarrow \Delta w = \delta_j^{(l)} \cdot x_i^{(l-1)}$$

$$\delta_j^{(l)} = \frac{\partial e(w)}{\partial s_j^{(l)}} \quad : (l=L, j=1) \quad \text{עבור השכבה האחרונה} \quad (*)$$

$$\Rightarrow \delta_1^{(L)} = \frac{\partial e(w)}{\partial s_1^{(L)}}$$

$$e(w) = (x_1^{(L)} - y)^2 = (\theta(s_1^{(L)}) - y)^2 \quad \text{לטן:}$$

$$\text{מכיוון ש: } \theta'(s) = 1 - \theta^2(s) \quad \text{נציב ונקבל:}$$

$$\delta_1^{(L)} = (1 - x_1^{(L)^2}) (x_1^{(L)} - y)$$

* העיטוי אמור להיות מוכפל פי 2 (מהנעצרת) אבל זה לא קריטי כי אפשר לשחק * עם ה-learning rate.


16/1/17

$$\delta_i^{(l-1)} = \frac{\partial e(w)}{\partial s_i^{(l-1)}} = \dots$$

⊛ עבור שכבה ה-1 : +

$$\dots = \sum_{j=1}^d \underbrace{\frac{\partial e(w)}{\partial s_j^{(l)}}}_{\text{השפאה}} \cdot \underbrace{\frac{\partial s_j^{(l)}}{\partial x_i^{(l-1)}}}_{\text{בסכום}} \cdot \underbrace{\frac{\partial x_i^{(l-1)}}{\partial s_i^{(l-1)}}}_{\text{אם ברר}} =$$

השפאה
בסכום
אם ברר
ה-1
ה-1
ה-1





$$= \sum_{j=1}^d \delta_j^{(l)} \cdot w_{ij}^{(l)} \theta'(s_i^{(l-1)}) =$$

$$= (1 - x_i^{(l-1)^2}) \sum_{j=1}^d w_{ij}^{(l)} \delta_j^{(l)}$$

Back Prop Algorithm:

- 1) Initialize $w_{ij}^{(l)}$
- 2) For $t=0 \dots T$
 - 2.1) Pick $n \in \{1, \dots, N\}$
 - 2.2) Forward: compute $x_j^{(l)}$
 - 2.3) Backward: compute $\delta_j^{(l)}$
 - 2.4) Update: $w_{ij}^{(l)} \leftarrow w_{ij}^{(l)} - \eta x_i^{(l-1)} \delta_j^{(l)}$
- 3) Return $w_{ij}^{(l)}$

tanh מקובל ReLU או זאת AlexNet-
 $f(x) = \max(x, 0)$



Vanishing gradients כי tanh ל-0

השפאה
בסכום
אם ברר
ה-1
ה-1
ה-1